

Итоговый проект по дисциплине «Анализ данных на Python»

Формула оценивания: Проект * 0.5

Итоговый проект выполняется в командах по 2-3 человека и защищается в очном формате на последнем занятии (занятие пройдет на неделе с 15 по 19 июня).

Рекомендуется объединяться в команды внутри своей подгруппы. Также допускается создание команд со студентами из других подгрупп (с 6-й по 10-ю).

Дедлайн загрузки работы в SmartLMS: до начала защит (перед началом соответствующей пары, на которой будет проходить Ваша защита). Работа загружается одним участником команды.

Пожалуйста, не забудьте отметить состав группы:

В рамках группового итогового проекта команде необходимо:

1. **Сбор данных.** Самостоятельно получить данные из выбранных источников. Допускается использование одного из следующих подходов: написание скрипта для веб-скрейпинга, работа с готовыми наборами данных (открытые репозитории, государственные порталы, платформенные датасеты), подключение к внешним API.
2. **Очистка и предобработка данных.** Провести работу с качеством данных: выявить и обработать пропущенные значения, обнаружить и проанализировать аномалии, привести данные к корректным типам, при необходимости выполнить нормализацию, кодирование категориальных признаков или создание новых переменных.
3. **Анализ данных.** Применить изученные методы анализа и машинного обучения для выявления закономерностей, взаимосвязей или трендов в данных. Выбор аналитических инструментов должен соответствовать поставленным исследовательским вопросам.
4. **Интерпретация и визуализация результатов.** Представить ключевые выводы в наглядной форме: построить графики, диаграммы, интерактивные элементы визуализации. Сформулировать содержательные выводы, отражающие практическую и исследовательскую ценность полученного результата.

Рекомендуемый перечень источников датасетов и данных для использования*:

Название	Ссылка
Официальные данные органов власти	
Федеральная служба государственной статистики РФ	http://www.gks.ru
Портал открытых данных РФ	https://fedstat.ru https://rosstat.gov.ru/
Государственная статистика РФ	http://data.gov.ru/
Портал открытых данных Перми	http://opendata.perm.ru
Портал открытых данных Правительства Москвы	https://data.mos.ru/
Данные компаний и организаций	
Статистические данные Всемирной организации здравоохранения	https://www.who.int/healthinfo/statistics/en/
Открытые данные Сбербанка	http://www.sberbank.com/ru/opendata
История изменения курса валют Центрального банка России	https://www.cbr.ru/currency_base/dynamics/ https://www.cbr.ru/development/SXML
World Bank Open Data	https://data.worldbank.org/
Данные конкурсов и агрегаторов	
Данные портала Kaggle	https://www.kaggle.com/datasets
Проект Data World	https://data.world
Data Mining Cup	https://www.data-mining-cup.com/reviews/
Microsoft Research Open Data	https://msropendata.com
Сайт DataMarket	https://datamarket.com/data/list/?q=provider:tsdl
Google Dataset Search	https://toolbox.google.com/datasetsearch
Google BigQuery Public Datasets	https://docs.cloud.google.com/bigquery/public-data
Google Takeout	https://takeout.google.com/
Данные, собранные проектом Gephi	https://github.com/gephi/gephi/wiki/Datasets
Duck Consulting Russia	https://russia.duck.consulting/
Коллекция данных, собранная университетом Стенфорда	http://snap.stanford.edu/data/
Данные об экономике России на сайте Высшей школы экономики	http://sophist.hse.ru/hse/nindex.shtml
Сайты — списки ссылок	
Перечень сайтов с открытыми данными	https://github.com/caesar0301/awesome-public-datasets

Наборы данных на Reddit	https://www.reddit.com/r/bigquery/wiki/datasets
CoinGecko API	https://www.coingecko.com/en/api
Spotify API	https://developer.spotify.com/documentation/web-api
Собранный частным лицом набор ссылок	https://kevinchai.net/datasets

*Если используете другие данные, пожалуйста, обязательно укажите их источник.

Оценка за итоговый проект выставляется по формуле:
0,5 * Выполнение проекта + 0,5 * Защита проекта

№1. Критерии выполнения проекта:

№	Критерий
Базовая часть (максимум 8 баллов)	
1	Сбор данных (до 2 баллов) ● 2 балла: Осуществлен сложный сбор: парсинг с пагинацией (несколько страниц) ИЛИ данные из готового датасета обогащены через сторонние API, выборка репрезентативна. ● 1 балл: Реализовано простое подключение к API / написан базовый парсер одной страницы ИЛИ использован сложный готовый датасет, который потребовал существенной адаптации (объединение нескольких таблиц, фильтрация большого объема) ● 0 баллов: Данные не собраны или просто скачан готовый .csv без обработки.
2	Предобработка и очистка данных (до 2 баллов) ● 2 балла: Дополнительно созданы новые расчетные признаки ИЛИ заполнены пропуски с помощью статистических методов. ● 1 балл: Проведена качественная очистка: обработаны пропуски, удалены дубликаты, изменены типы данных, обработаны аномалии/выбросы. ● 0 баллов: Очистка не проведена.

3	Анализ данных (до 2 баллов) ● 2 балла: Проведен глубокий разведочный анализ, сформулированы и проверены логичные гипотезы, корректно применены статистические инструменты, изученные в курсе. ● 1 балл: Выполнен базовый анализ (группировки, сводные таблицы, расчет средних/медиан). ● 0 баллов: Анализ не представлен ИЛИ проведен, но были допущены значительные ошибки в ходе анализа И/ИЛИ интерпретации результатов.
4	Визуализация (до 1 балла) ● 1 балл: Построены содержательные графики (не менее 3-4 разных типов). Оценивается оформление: наличие заголовков, подписей осей, легенды, читаемость цветов и выбор подходящего типа графика под задачу. ● 0 баллов: Отсутствуют подписи осей, графиков, легенды
5	Качество кода и оформление (до 1 балла) ● 1 балл: Код соответствует стандартам PEP-8 (читаемые названия переменных), отсутствуют неиспользуемые куски кода. В Jupyter Notebook/Google Colab есть структура: используются Markdown-ячейки с заголовками, текстовыми пояснениями и промежуточными выводами. ● 0 баллов: Код не задокументирован, отсутствие комментариев, И/ИЛИ допущены ошибки при запуске кода.
Продвинутая часть (9-10 баллов) Оценки 9 и 10 выставляются за работы, которые превосходят базовые требования курса. Для получения дополнительных баллов команде необходимо реализовать не более 2-х технических усложнений. Примеры приведены ниже:	

7	1. Глубокая продуктовая аналитика (+1 балл): Вы решили реальную бизнес-задачу. Например, провели когортный анализ, RFM-сегментацию аудитории, рассчитали Unit-экономику или провели сложный анализ временных рядов (поиск тренда и сезонности). 2. Публичный вклад (Data Storytelling) (+1 балл): Проект оформлен как готовое портфолио: репозиторий на GitHub/Kaggle со строгой структурой (README.md, requirements.txt) ИЛИ выложен уникальный очищенный датасет на Kaggle ИЛИ опубликована аналитическая статья на основе исследования (Habr, VC.ru). 3. Собственное техническое усложнение (+1 балл): Команда может предложить собственное усложнение, предварительно согласованное с преподавателем, которое существенно превышает уровень курса (например, асинхронный парсинг, написание unit-тестов, контейнеризация Docker).
---	--

Важно: Студенты могут использовать любые AI-инструменты как помощников. При использовании AI-инструментов необходимо задекларировать их использование и показать, какие задачи выполнялись с помощью AI. Тем не менее, на защите каждый участник должен уметь объяснить логику работы любой строчки кода (содержательного блока) в своем проекте.

№2. Критерии защиты проекта:

1. Качество доклада и структура выступления (до 2 баллов)

- 2 балла: Доклад выстроен логично, обладает четкой структурой и полностью соответствует регламенту времени (до 15 минут выступление). В выступлении расставлены акценты на целях исследования, методологии анализа и ключевых аналитических результатах, а не на техническом описании строк кода.
- 1 балл: В структуре доклада нарушена последовательность изложения (пропущены смысловые блоки, такие как источник данных, работа по очистке данных и т.п.), допущены отклонения от временного регламента, либо содержание выступления смещено в сторону технического описания кода в ущерб демонстрации аналитических выводов.
- 0 баллов: Выступление не демонстрирует предварительной подготовки, доклад сводится к дословному прочтению текстовых материалов со слайдов.

2. Визуальное оформление презентации (до 2 баллов)

Единый шаблон презентации: <https://www.hse.ru/info/brandbook/>

- 2 балла: Презентация выполнена в едином графическом стиле, текстовая информация на слайдах структурирована и не избыточна. Иллюстративные материалы и графики из расчетной части перенесены в высоком разрешении, все элементы визуализации (названия, подписи осей, легенды) легко читаемы.
- 1 балл: на слайдах присутствует избыточный объем сплошного текста, графические материалы имеют низкое разрешение или недостаточный размер, отсутствуют обязательные элементы оформления графиков (подписи осей, легенды), либо нарушено стилистическое единство презентации.
- 0 баллов: Презентация к защите не представлена, либо ее оформление не соответствует минимальным требованиям к демонстрационным материалам.

3. Командное взаимодействие и распределение ролей (до 2 баллов)

- 2 балла: Материал доклада распределен между участниками равномерно. Выступление носит скоординированный характер, переходы между спикерами последовательны, каждый член команды в полной мере представляет результаты закрепленного за ним этапа работы (сбор, очистка, анализ ИЛИ формулирование выводов).
- 1 балл: Распределение нагрузки в ходе презентации неравномерно: в докладе преобладает один участник, в то время как участие остальных носит номинальный характер, либо в процессе выступления фиксируются нарушения согласованности и очередности доклада спикеров.
- 0 баллов: Командное взаимодействие в процессе защиты не демонстрируется, доклад полностью обеспечивается силами только одного студента. **(Если студент не участвует в выступлении, то 0 баллов)**

4. Ответы на вопросы и глубина понимания кода (до 3 баллов)

(На защите будет задан минимум 1 вопрос для каждого участника команды)

- **3 балла:** Команда развернуто отвечает на вопросы, демонстрируя полное понимание логики алгоритмов и структуры проекта, а каждый участник может детально объяснить назначение и реализацию любой строки кода в своем содержательном блоке.
- **2 балла:** Команда отвечает на большинство вопросов, демонстрируя понимание общей архитектуры проекта, однако при детализации работы отдельных функций или алгоритмов возникают затруднения и неточности.

- **1 балл:** Команда испытывает значительные трудности с ответами, а участники не могут дать пояснения по назначению параметров, функций или логике выполнения кода в своих частях проекта.
- **0 баллов:** Ответы на заданные вопросы полностью отсутствуют.

Всем успехов в выполнении итогового проекта!